Архитектура и методология дообучения моделей семейства Qwen для переноса литературного стиля Федора Достоевского

Проблема автоматического переноса стиля текста (Text Style Transfer, TST) представляет собой одну из наиболее сложных задач в области генерации естественного языка и вычислительной лингвистики. Фундаментальная цель данной процедуры заключается в изменении стилистических атрибутов исходного текста — таких как тональность, авторский почерк, уровень формальности или эмоциональная окраска — при строгом сохранении его исходной семантической информации.[1] В контексте применения этой технологии к классической русской литературе, и в частности к произведениям Федора Михайловича Достоевского, вычислительная и лингвистическая сложность задачи возрастает экспоненциально. Проза Достоевского не сводится к простому набору архаичной лексики или устаревших грамматических конструкций; она определяется сложнейшими структурными элементами, глубоким психологическим напряжением и уникальной нарративной полифонией, которая требует от языковых моделей высочайшего уровня абстракции.[4]

Исторически алгоритмы машинного перевода и стилистической адаптации сталкивались с проблемой нехватки параллельных корпусов данных — наборов текстов, содержащих идентичный смысл, но написанных в разных стилях.[2] В отличие от классического машинного перевода, где существуют огромные массивы данных, сопоставляющих английский язык с русским, в природе не существует естественных массивов, которые бы напрямую сопоставляли современный, нейтральный русский язык с литературным языком девятнадцатого века в стиле Достоевского. Следовательно, успешное выполнение данной задачи требует разработки многоуровневого пайплайна, который включает в себя синтез искусственных обучающих данных, выбор оптимальной базовой архитектуры языковой модели, применение эффективных методов параметр-эффективного дообучения (PEFT) с учетом аппаратных ограничений облачных платформ, а также внедрение строгой системы метрик для оценки качества генерации.[6] Настоящий отчет представляет собой исчерпывающий анализ и руководство по созданию такой системы, ориентированной на использование облачной среды Kaggle и открытых моделей серии Qwen.

Выбор и обоснование базовой архитектуры: Семейство моделей Qwen

Успешный перенос сложного литературного стиля невозможен без использования высокопроизводительной базовой модели (Foundation Model), обладающей глубоким

пониманием морфологии, синтаксиса и семантики целевого языка. В последние годы архитектура Qwen, разработанная исследовательской группой Alibaba Cloud, зарекомендовала себя как одно из самых передовых решений в области открытых языковых моделей с открытыми весами (open-weight).[9] Важнейшим преимуществом семейства Qwen является его изначальная мультиязычная ориентация. В отличие от многих западных аналогов, которые центрированы преимущественно на английском языке, модели Qwen обучались на огромных массивах данных, охватывающих 119 языков и диалектов, включая колоссальный объем русскоязычных текстов, что обеспечивает им врожденную способность к сложной лексической и синтаксической работе с русским языком.[9]

Выбор конкретной модификации модели напрямую диктуется аппаратными ограничениями целевой вычислительной платформы. Бесплатные инстансы платформы Kaggle предоставляют доступ к графическим ускорителям NVIDIA Tesla T4, каждый из которых оснащен 16 гигабайтами видеопамяти (VRAM).[12] Данное ограничение делает невозможным использование сверхбольших моделей с десятками миллиардов параметров (таких как Qwen 3 32B или 72B) без применения экстремального квантования, которое разрушает тонкие стилистические паттерны. В то же время, сверхлегкие модели (от 0.5B до 3B параметров) не обладают достаточной емкостью репрезентативного пространства для удержания сложных нарративных структур Достоевского, склонны к галлюцинациям и быстрой потере контекста при изменении стиля.[15]

Исходя из этого, оптимальным компромиссом между репрезентативной мощностью и аппаратными требованиями выступают модели с объемом параметров от 7 до 8 миллиардов. В рамках экосистемы Qwen на 2026 год существуют два основных кандидата в данной весовой категории, архитектурные особенности которых требуют детального сравнения.

Характеристика архитектуры	**Модель Qwen 2.5 7B Instruct**	**Модель Qwen 3 8B**
Общее количество параметров	7.61 миллиарда (из них 6.53 млрд не-эмбеддинговых) [16]	8.2 миллиарда [17]
Количество слоев (Layers)	28 слоев [16]	36 слоев [9]
Конфигурация голов внимания	28 голов запросов (Q), 4 головы ключей/значений (KV) [16]	32 головы запросов (Q), 8 голов ключей/значений (KV) [9]
Базовое контекстное окно	До 131,072 токенов (использование YaRN) [16]	До 128,000 токенов [9]
Интеграция когнитивных режимов	Отсутствует (классический инструктивный режим) [11]	Поддержка переключения между режимом «размышления» (Thinking Mode) и быстрым ответом (Non-Thinking Mode) [9]

Объем обучающей выборки (Pre-training)	18 триллионов токенов [19]	36 триллионов токенов [9]

Обе модели построены на базе усовершенствованной архитектуры трансформеров с применением механизмов ротаторного позиционного кодирования (RoPE), функций активации SwiGLU, нормализации RMSNorm и механизма Grouped Query Attention (GQA), который критически важен для снижения потребления памяти кэшом ключей-значений при генерации длинных текстов.[11] Модель Qwen 3 8B демонстрирует более совершенное понимание сложных инструкций благодаря удвоенному объему обучающей выборки и увеличенному числу слоев, что позволяет ей лучше улавливать нюансы многослойной русской литературы.[9] Тем не менее, версия Qwen 2.5 7B Instruct остается высокоактуальной благодаря своей исключительной предсказуемости при следовании системным промптам и высокой степени выравнивания (alignment) с пользовательскими намерениями, что минимизирует риски потери исходного смысла при переносе стиля.[11]
Для задачи стилистической трансформации текста обе модели обеспечивают необходимый фундамент, однако использование Qwen 3 8B предпочтительнее ввиду ее расширенной базы знаний о редких лингвистических конструкциях (long-tail knowledge) и улучшенных возможностей логического вывода в режиме "Thinking Mode", что позволяет модели перед генерацией ответа внутренне проанализировать исходный текст на предмет ключевых семантических узлов, которые не должны быть утеряны.[9]

Аппаратная оптимизация в среде Kaggle: Роль библиотеки Unsloth

Запуск процесса дообучения модели масштаба 8 миллиардов параметров на одном графическом ускорителе NVIDIA Tesla T4 с 16 ГБ видеопамяти представляет собой серьезную инженерную задачу. В стандартной 16-битной точности (FP16 или BF16) только загрузка весов модели потребует около 16 гигабайт VRAM, что не оставит свободного пространства для состояний оптимизатора, кэширования градиентов и хранения активаций во время прямого и обратного проходов нейронной сети. Для преодоления этого фундаментального барьера необходимо применение методов квантования в сочетании с передовыми программными оптимизаторами.
Ключевым инструментом в данном процессе выступает библиотека Unsloth. Этот фреймворк кардинально изменяет вычислительный ландшафт дообучения больших языковых моделей путем внедрения оптимизированных ядер (kernels), написанных на языке Triton.[7] Ядра Unsloth заменяют стандартные вычислительные операции библиотеки Hugging Face Transformers, что позволяет ускорить процесс обучения в 2-5 раз и одновременно снизить потребление видеопамяти на 60-70% по сравнению с классическим подходом, использующим комбинацию Flash Attention 2 и стандартного Hugging Face.[7]
Инициализация инфраструктуры на платформе Kaggle требует осторожного подхода к управлению зависимостями. Среда Kaggle по умолчанию поставляется с предварительно установленными пакетами PyTorch и различными библиотеками для работы с данными,

версии которых могут конфликтовать с новейшими релизами ядра Unsloth. Практика показывает, что для избежания конфликтов компиляции и ошибок регистрации фабрик cuFFT и cuBLAS необходимо применять стратегии принудительной переустановки пакетов без использования кэша.[14] Процесс развертывания должен начинаться с полного удаления устаревших зависимостей PyTorch и xformers с последующей их чистой установкой через официальные индексы NVIDIA.[25] Инсталляция самого фреймворка Unsloth должна производиться непосредственно из репозитория GitHub для получения последних патчей, исправляющих ошибки градиентного накопления (gradient accumulation) и проблемы с токенизацией.[27]

После подготовки окружения модель загружается в видеопамять с использованием 4-битного квантования (алгоритм NormalFloat4, реализованный в библиотеке bitsandbytes). Включение параметра load_in_4bit = True в методе инициализации FastLanguageModel позволяет сжать базовые веса модели Qwen 3 8B с 16 ГБ до приблизительно 5.5 ГБ, что освобождает необходимый объем памяти для размещения обучаемых адаптеров и промежуточных вычислений.[18] При этом важно отметить, что Unsloth обеспечивает нулевую потерю точности при конвертации слоев, не прибегая к аппроксимирующим методам, ухудшающим качество языкового моделирования.[23]

Дополнительным критическим параметром конфигурации памяти выступает механизм контрольных точек градиентов (gradient checkpointing). Данная техника позволяет не хранить все промежуточные активации во время прямого прохода, а пересчитывать их по мере необходимости во время обратного распространения ошибки. Фреймворк Unsloth предлагает собственный, более агрессивный алгоритм сохранения памяти, который активируется параметром use_gradient_checkpointing = "unsloth". Это позволяет эффективно обрабатывать более длинные входные последовательности текста (что критично для абзацев Достоевского) и использовать увеличенный размер пакета (batch size), предотвращая возникновение ошибок нехватки памяти (OOM) на Tesla T4.[23]

Лингвистическое и стилистическое профилирование прозы Достоевского

Перенос стиля не может опираться исключительно на замену современной лексики на устаревшие слова XIX века. Для того чтобы языковая модель смогла достоверно воспроизвести стилистику Федора Достоевского, необходимо провести глубокую декомпозицию его литературного почерка и формализовать эти признаки в виде паттернов, понятных нейронной сети при дообучении. Литературоведческий и лингвистический анализ выявляет существенные структурные отклонения текстов Достоевского от усредненного литературного стандарта его эпохи, что делает его стиль одновременно легко узнаваемым и крайне сложным для алгоритмического синтеза.[4]

В отличие от детализированного, размеренного и бытоописательного реализма Льва Толстого, проза Достоевского характеризуется колоссальным внутренним напряжением, полифонизмом и доминированием психологического давления над физическим описанием сцен.[5] Достоевский намеренно нарушает академическую гладкость речи,

создавая текст, который Владимир Набоков характеризовал как "поток и нагромождение слов с бесконечными повторениями, бормотанием в сторону и словесным переполнением".[32] Этот литературный хаос не является следствием небрежности; он служит мощным инструментом отражения экзистенциального кризиса, моральной двойственности и лихорадочного состояния сознания его персонажей.
Для успешного обучения модели Qwen необходимо выделить конкретные лингвистические маркеры, которые поддаются квантификации:

Лингвистический уровень	**Специфические маркеры прозы Ф.М. Достоевского**	**Функциональная роль в тексте**
Синтаксис	Бесконечные цепи сложносочиненных и сложноподчиненных предложений, полисиндетон (многосоюзие), парцелляция.	Создание эффекта лихорадочного размышления, сбивающегося дыхания и непрерывного потока сознания персонажа.[32]
Лексика и морфология	Гипертрофированное использование слов-усилителей (интенсификаторов), абсолютных терминов ("совершенно", "никогда", "абсолютно") и отрицательных местоимений.	Отражение максимализма, бескомпромиссности внутренних конфликтов и склонности к крайностям в суждениях героев.[32]
Риторика	Обилие риторических вопросов, парадоксальных утверждений и антитез, когда мысль моментально опровергается последующим утверждением.	Формирование моральной двойственности и экзистенциального сомнения, подчеркивание того, что человек сознательно выбирает нелогичные пути.[32]
Композиция	Внезапные философские отступления, прерывающие действие для рассуждений о Боге, страдании, свободе воли и границах человеческого разума.	Подтверждение того, что произведения "сотканы исключительно из материи души", перенос фокуса с событий на метафизику.[4]

Следовательно, задача дообучения состоит не в том, чтобы просто добавить в текст слова "сударь" или "извольте", а в том, чтобы заставить модель перестраивать логическую структуру современного предложения. Нейтральный современный текст, передающий простой факт (например, "Он решил не идти на работу, потому что чувствовал себя плохо"), в целевом стиле должен обрастать избыточной рефлексией, парадоксами и многослойным синтаксисом (например, "Да и полно, стоило ли вообще идти туда, в эту канцелярию, когда все нутро его, казалось, решительно и окончательно восставало

против малейшего движения; и ведь не из лени вовсе, о нет, если бы только из лени, как бы он сам себя тогда уважал!"). Модель должна научиться генерировать подобную синтаксическую проликсити, не теряя при этом базовой семантики исходного текста.[32]

Проектирование и синтез параллельного корпуса данных

Критическим ограничением в области переноса текста (TST) является отсутствие масштабных параллельных корпусов данных. В отличие от задач суммаризации или машинного перевода, где существуют пары "длинный текст - короткий текст" или "английский - русский", тексты Достоевского существуют только в одном, оригинальном варианте.[2] Модель машинного обучения нуждается в сильном супервизорном сигнале (Supervised Fine-Tuning, SFT), который может быть обеспечен только качественным набором парных примеров, где каждому нейтральному входному тексту соответствует стилистически трансформированный выходной текст.[2]

Для решения этой проблемы применяется стратегия синтетической генерации данных с использованием цепочек рассуждений (Chain-of-Thought, CoT) и методов обратного перевода (round-trip translation).[2] Процесс создания датасета состоит из следующих этапов:

Сначала собирается корпус оригинальных текстов Федора Достоевского, находящихся в общественном достоянии ("Преступление и наказание", "Братья Карамазовы", "Записки из подполья"). Из этих текстов извлекаются абзацы, репрезентативные с точки зрения описанного выше лингвистического профиля.[31] Затем эти тексты подвергаются процедуре семантической "нейтрализации". Это может достигаться путем перевода русского текста на промежуточный язык (например, английский) с помощью стандартной нейросетевой модели перевода, а затем обратного перевода на русский язык.[6] В процессе такого двойного перевода уникальная синтаксическая структура, архаизмы и эмоциональная насыщенность теряются, оставляя лишь базовую семантику ("нейтрализованный" текст). Таким образом создается пара: искусственно созданный нейтральный текст (вход) и оригинальный текст Достоевского (целевой выход).[6]

Альтернативный подход заключается в использовании мощных проприетарных или открытых моделей-учителей (таких как Qwen 3 235B в режиме логического вывода или DeepSeek R1) для прямой генерации стилистических переписываний нейтральных текстов с использованием детальных системных промптов и алгоритмов few-shot (обучения на нескольких примерах).[9]

Ключевым аспектом подготовки данных для Unsloth и библиотеки TRL является правильное форматирование. Датасет должен быть строго структурирован в формате диалога, с ролями "system", "user" и "assistant".[27] Несоответствие формата данных изначальному шаблону чата (chat template), на котором обучалась базовая модель Qwen, приводит к катастрофической нестабильности обучения и генерации бесконечных повторяющихся токенов.[30] Важно учитывать техническую особенность моделей Qwen 2.5: в их базовых версиях (не Instruct) токены <|im_start|> и <|im_end|> не были должным

образом обучены, и их использование может привести к критическим ошибкам генерации.[24] Поэтому при дообучении необходимо использовать именно Instruct-версии моделей, где эти служебные токены уже встроены в репрезентативное пространство модели, и строго соблюдать формат HuggingFace ("role", "content").[24]

Роль в шаблоне	Содержание и функция в наборе данных
System	Системный промпт, задающий непрерывный контекст для модели. Включает строгие инструкции по поддержанию экзистенциального тона, использованию сложного синтаксиса и сохранению фактологии исходного текста. Устанавливает рамки дозволенного поведения нейронной сети.[39]
User	Исходный современный, нейтральный текст, лишенный философской окраски и сложных риторических фигур. Этот текст выступает семантическим якорем, смысл которого модель обязана полностью сохранить.[8]
Assistant	Целевой текст, демонстрирующий стиль Достоевского (сгенерированный синтетически или взятый из оригинальных произведений при обратном переводе). Этот текст используется функцией потерь (loss function) для расчета ошибки при обратном распространении градиента.[2]

Эмпирические данные показывают, что для сложных задач переноса стиля качество датасета имеет абсолютный приоритет над его размером. Обучение на высококачественной, тщательно очищенной выборке из 4,000–10,000 парных примеров дает значительно лучший результат, чем использование сотен тысяч зашумленных текстов, что также позволяет существенно сократить время обучения на платформе Kaggle, укладываясь в доступные квоты.[41] Более того, в датасет рекомендуется добавлять небольшое количество (5-10%) примеров, где стиль не должен изменяться (нейтральный текст остается нейтральным), что выступает в роли регуляризатора и предотвращает переобучение модели, заставляя ее внимательно следить за инструкциями в системном промпте, а не слепо применять один и тот же фильтр ко всем входам.[31]

Методология параметр-эффективного дообучения (PEFT): Переход от LoRA к DoRA

Поскольку полное обновление всех параметров 8-миллиардной модели Qwen (Full Fine-Tuning) на графическом процессоре потребительского класса невозможно,

необходимо применять методы параметр-эффективного дообучения (Parameter-Efficient Fine-Tuning, PEFT). Исторически стандартом де-факто в этой области выступал метод низкоранговой адаптации (Low-Rank Adaptation, LoRA). Суть метода LoRA заключается в том, что весовые матрицы предварительно обученной модели замораживаются, а в архитектуру трансформера интегрируются небольшие обучаемые матрицы разложения низкого ранга. Вместо обновления полной матрицы весов W, процесс обучения оптимизирует матрицы B и A, а итоговое обновление вычисляется как $W' = W + \frac{\alpha}{r}BA$, где r — ранг матрицы, а α — коэффициент масштабирования.[43] Это позволяет сократить количество обучаемых параметров в сотни раз, снижая требования к видеопамяти.[43]

Однако, как показывает глубокий технический анализ процесса дообучения модели Qwen 3 8B, опубликованный на портале Habr, стандартный метод LoRA может оказаться недостаточным для задач, требующих сложной адаптации предметной области при строгом сохранении фактологии.[7] При работе со сложными паттернами (в статье описывалась адаптация модели под строгие медицинские диагнозы МКБ-10, что концептуально близко к задаче сохранения жесткой семантики при полной смене стилистической формы) стандартная LoRA страдает от проблемы "катастрофического забывания" (catastrophic forgetting). Модель либо усваивает новый стиль, полностью теряя способность к логическому мышлению и сохранению фактов исходного текста, либо сохраняет факты, но игнорирует стиль.

Оптимальным решением, доказавшим свою эффективность на модели Qwen 3 8B, является использование метода DoRA (Weight-Decomposed Low-Rank Adaptation).[7] В отличие от классического подхода, DoRA декомпозирует предварительно обученные веса модели на два независимых компонента: вектор амплитуды (magnitude) и матрицу направления (direction). Низкоранговая адаптация применяется исключительно к компоненту направления. Это позволяет модели более гибко настраиваться на сложные стилистические изменения, не затрагивая при этом глубинные знания (амплитуду), полученные на этапе предварительного обучения на десятках триллионов токенов. Использование DoRA кардинально снижает риск галлюцинаций и потери смыслового ядра исходного текста.[7]

Конфигурация гиперпараметров DoRA/LoRA является критически важной для успеха стилистической трансформации текста и требует соблюдения следующих экспериментально подтвержденных правил:

Параметр адаптации	**Рекомендуемое значение**	**Теоретическое и эмпирическое обоснование**
Целевые модули (Target Modules)	q_proj, k_proj, v_proj, o_proj, gate_proj, up_proj, down_proj	Для переноса сложного литературного стиля адаптации только слоев внимания (Attention)

		абсолютно недостаточно. Основная масса знаний модели и ее лингвистические паттерны хранятся в слоях многослойного персептрона (MLP). Интеграция адаптеров в слои gate_proj, up_proj, down_proj строго обязательна для достижения приемлемого результата.[7]
Ранг матриц (Rank, r)	От 32 до 64	Хотя для простых задач форматирования ответов достаточно ранга 4-8, задача захвата плотного психологического синтаксиса и полифонии Достоевского требует высокой параметрической емкости. Исследования показывают, что при ранге ниже 32 наблюдается острая форма катастрофического забывания: модель хуже справляется с сохранением ранее изученной информации и демонстрирует деградацию связности речи.[7]
Масштабирующий фактор (Alpha, α)	От 32 до 64	Классическая рекомендация заключается в поддержании соотношения $\alpha =$ или $\alpha =$. Для модели Qwen 8B, обладающей сильными внутренними связями, высокий коэффициент α позволяет новым стилистическим матрицам эффективно влиять на замороженные веса, не перегружая при этом процесс вычисления

		градиентов.[43]
Dropout (Случайное отключение нейронов)	0.0	При использовании 4-битного квантования через библиотеку Unsloth параметр Dropout должен быть строго равен нулю. Попытка его увеличения приводит к нестабильности вычислений внутри оптимизированных ядер Triton и ошибкам переполнения типов данных.[43]

Организация тренировочного цикла (training loop) осуществляется с помощью модуля SFTTrainer (Supervised Fine-tuning Trainer) из библиотеки TRL.[23] Выбор скорости обучения (learning rate) является зоной высокой чувствительности: значение порядка 2×10^{-4} в комбинации с 8-битным оптимизатором AdamW (optim = "adamw_8bit") обеспечивает стабильную траекторию градиентного спуска, экономя при этом ценную память графического процессора.[41] Использование планировщика скорости обучения (scheduler) с косинусным затуханием и периодом разогрева (warmup ratio) около 10% гарантирует, что веса адаптеров не подвергнутся эффекту градиентного взрыва на начальных этапах обучения.[15]

Размер батча (batch size) должен быть минимизирован до 2 или 4 в зависимости от длины контекста, с применением накопления градиентов (gradient accumulation steps, например, 4 или 8) для имитации большего размера пакета и стабилизации вектора обновления.[15]

Длительность обучения не должна превышать 1-3 эпох; превышение этого лимита резко увеличивает вероятность переобучения (overfitting), при котором модель начинает слепо заучивать тексты из обучающей выборки, теряя способность генерализовать стиль на новые, неизвестные ей ранее современные тексты.[15]

Системный промптинг и механика инференса

Переход от фазы обучения к фазе логического вывода (инференсу) требует абсолютного соответствия в форматах текстовых запросов. Если шаблон чата (chat template), применяемый во время логического вывода, хотя бы минимально отличается от шаблона, использовавшегося при дообучении, модель теряет ассоциативные связи, сформированные в весах DoRA. Это проявляется в резкой деградации качества генерации, бесконечных циклах повторения одного и того же слова или полной потере стилистических приобретений.[30]

Системный промпт функционирует как главный механизм кондиционирования нейронной сети. Для задачи переноса стиля Достоевского он не должен ограничиваться тривиальным указанием "Пиши как Достоевский". Как показывают исследования в области prompt engineering, для сложных стилизаций системный промпт должен содержать явные

указания на ожидаемое синтаксическое, лексическое и структурное поведение модели.[40] Эффективный промпт разлагает стиль на исполняемые директивы: требование использовать многосоюзие, предписание вставлять риторические вопросы для имитации внутренней борьбы, а также строгий запрет на добавление фактической информации, отсутствующей во входном тексте пользователя. Практика показывает, что модель Qwen 2.5 обладает исключительной устойчивостью к таким сложным системным инструкциям, что позволяет точно настраивать глубину стилизации.[11]

Механика инференса также управляется термодинамическими гиперпараметрами генерации. Температура генерации (Temperature) контролирует степень случайности при выборе следующего токена. Для переноса стиля оптимальным диапазоном является значение от 0.5 до 0.7.[17] Слишком низкая температура делает текст сухим и механистичным, лишая его литературного изящества, в то время как температура выше 0.8 приводит к семантическим галлюцинациям и разрушению логики сложных предложений. Параметр Top-P (выборка из ядра) рекомендуется устанавливать на уровне 0.95 для обеспечения достаточного лексического разнообразия при отсечении откровенно нерелевантных токенов.[17] Кроме того, внедрение штрафа за повторение (repetition penalty) на уровне 1.1 критически важно для предотвращения рекурсивных синтаксических циклов — распространенной проблемы при генерации длинной русскоязычной прозы с использованием моделей малого и среднего размера.[48]

Трехкомпонентная система оценки качества переноса стиля

Оценка эффективности моделей переноса стиля (TST) представляет собой одну из самых острых проблем в современной NLP-индустрии, так как успех не может быть сведен к единой скалярной метрике. Успешный перенос должен быть оценен по трем независимым, а зачастую и конфликтующим осям: точность переноса стиля (Style Transfer Accuracy), сохранение содержания (Content Preservation) и беглость/естественность речи (Fluency).[1] Модели часто демонстрируют компромисс между этими метриками: например, алгоритм может достичь идеального стилевого сходства путем генерации абсолютно нового текста, полностью уничтожив исходный смысл, или, наоборот, сохранить 100% содержания, выдав текст без малейших признаков целевого стиля.[50]

Для всесторонней верификации дообученной модели Qwen необходимо применение гибридного подхода, объединяющего специализированные лингвистические инструменты, традиционные метрики оценки машинного перевода и методы оценки с использованием больших языковых моделей в качестве судей (LLM-as-a-Judge).[1]

1. Оценка точности стиля с помощью StyloMetrix

Традиционные n-граммные метрики (BLEU, ROUGE) абсолютно непригодны для измерения стилистической согласованности. Для объективной квантификации стиля необходимо применять инструменты стилометрии. Библиотека StyloMetrix представляет

собой передовой фреймворк, способный преобразовывать текст в нормализованные векторы, которые отражают количественные характеристики лингвистических паттернов, создавая таким образом уникальную "стилометрическую сигнатуру" текста.[52] Стилометрический анализ русского языка в StyloMetrix опирается на языковую модель ru_core_news_lg платформы spaCy, что позволяет извлекать высокоспецифичные лексические и синтаксические особенности, характерные для русской грамматики.[52] Для оценки сходства сгенерированного текста с эталонной прозой Достоевского рассчитывается дифференциал между сгенерированным текстом и базовым корпусом писателя по ключевым метрикам.

Категория StyloMetrix	**Идентификатор и метрика для русского языка**	**Интерпретация в контексте стиля Достоевского**
Лексическая (Lexical)	Id 44: Частотность отрицательных местоимений (Incidence of negative pronoun) [34]	Количественно отражает уровень пессимизма, внутреннего отрицания и противоречивости, свойственных героям Достоевского. Высокий показатель сближает текст с целевым стилем.
Лексическая (Lexical)	Id 34: Частотность пунктуации, в частности запятых (Incidence of comma) [34]	Выступает прямым индикатором синтаксической проликсити (многословия), использования длинных цепей зависимых предложений и парцелляции, характерных для лихорадочной речи.[32]
Лексическая (Lexical)	Id 32: Частотность косвенных прилагательных (Incidence of indirect adjective) [34]	Отражает переход от конкретных, современных описаний к более абстрактной, философской и описательной прозе девятнадцатого века.
Синтаксическая (Syntactic)	Id 60: Частота инверсных паттернов (Incidents of inverse patterns) [55]	Оценивает использование нестандартного порядка слов (анастрофы). Достоевский часто применяет инверсию для создания смысловых акцентов и передачи психологического диссонанса.

Вычисляя косинусное сходство или расстояние между стилометрическими векторами, сгенерированными дообученной моделью Qwen, и векторами, полученными из оригинальных текстов "Братьев Карамазовых" или "Идиота", исследователи получают строгую, воспроизводимую и независимую от длины текста метрику стилистического попадания.[52]

2. Оценка сохранения контента с помощью метрики METEOR

Чтобы гарантировать, что модель не исказила фактологию исходного нейтрального текста, применяются метрики семантического сохранения. Практика дообучения Qwen 3 8B, описанная в исследовании на Habr, однозначно указывает на метрику METEOR (Metric for Evaluation of Translation with Explicit ORdering) как на наиболее подходящий инструмент оценки валидационного набора данных.[7]

Классические метрики, такие как BLEU, требуют точного совпадения слов (токенов). При переносе стиля это становится неразрешимой проблемой: алгоритм намеренно заменяет современные слова на исторические синонимы, что приводит к нулевому значению BLEU, даже если смысл остался абсолютно идентичным. Метрика METEOR решает эту проблему путем вычисления гармонического среднего между точностью и полнотой униграмм, но, что критически важно, она использует встроенные алгоритмы стемминга (выделения основы слова) и базы синонимов.[7] Благодаря этому METEOR "понимает", что замена слова "подросток" на "отрок" или "комната" на "каморка" не меняет семантического ядра предложения. Высокое значение METEOR на валидационной выборке подтверждает, что применение матриц DoRA не привело к деградации смысловых ассоциаций в модели.[7]

3. Оценка беглости и комплексного качества (LLM-as-a-Judge)

Третий, завершающий уровень оценки компенсирует недостатки детерминированных алгоритмов путем использования передовых языковых моделей (таких как Qwen 3 235B, DeepSeek R1 или проприетарных аналогов) в роли автономных экспертов, что в современной индустрии получило название "LLM-as-a-Judge" (Языковая модель как судья).[1] Данная парадигма позволяет масштабируемо оценивать такие трудно уловимые свойства текста, как читабельность, естественность течения мысли и уместность использованной лексики в заданном контексте.

Процедура требует создания жестко структурированных промпт-шаблонов (prompt templates), которые исключают двусмысленность толкования. Модели-судье предоставляются исходный нейтральный текст и текст, сгенерированный дообученной моделью Qwen.[59] Промпт обязывает модель-судью не просто выдать вердикт, а сгенерировать цепочку рассуждений (Chain-of-Thought), анализируя ответ по конкретным критериям, после чего присвоить оценку по шкале Лайкерта (например, от 1 до 5).[59] В промпте должны быть даны явные определения для каждого балла оценки, чтобы минимизировать вариативность суждений.

Для задачи стилизации под Достоевского модель-судья должна сфокусироваться на следующих аспектах:

- Обладает ли текст естественной грамматической беглостью, характерной для

литературного русского языка, или же в нем присутствуют механистичные паттерны и артефакты генерации?
- Насколько органично лексика девятнадцатого века интегрирована в семантическую структуру предложений, не возникает ли эффекта искусственного, комичного нагромождения архаизмов?
- Являются ли внедренные философские отступления логически связанными с основным действием текста, или они выглядят как инородные вставки?

Научные исследования подтверждают, что при использовании тщательно настроенных промптов и высокоинтеллектуальных базовых моделей, оценки LLM-судей демонстрируют высокую корреляцию с оценками живых экспертов-лингвистов (что измеряется через коэффициент ранговой корреляции Кендалла Тау).[58] Это делает LLM-as-a-Judge незаменимым, надежным и экономически эффективным инструментом валидации стилистических моделей перед их развертыванием в рабочей среде.[60]

Практическое развертывание и экспорт модели

Завершающим этапом, следующим за успешной валидацией модели по описанным метрикам, является экспорт дообученных весов для практического применения (инференса). Фреймворк Unsloth предоставляет встроенные утилиты для сохранения адаптированных весов и их объединения с базовой моделью Qwen 8B. Для обеспечения совместимости с передовыми серверами инференса (vLLM, Ollama, llama.cpp), обученная модель может быть экспортирована в форматы Hugging Face safetensors или квантованный формат GGUF, что обеспечивает сверхбыструю генерацию токенов на различных аппаратных архитектурах, включая процессоры Apple Silicon серии M.[7]
Однако здесь кроется критический технологический нюанс, выявленный в процессе практических тестов: формат GGUF на текущий момент не обладает нативной поддержкой векторной декомпозиции, которая лежит в основе метода DoRA.[7] Следовательно, при экспорте модели адаптеры DoRA должны быть математически слиты (merged) с базовыми весами модели с восстановлением 16-битной точности перед финальным преобразованием в GGUF или 4-битную квантованную форму для инференса.[7] Этот процесс должен выполняться строго в оперативной памяти (RAM) для избежания искажения весовых коэффициентов.
При развертывании модели Qwen 3 8B или Qwen 2.5 7B для реального применения в сфере переноса стиля, их колоссальное контекстное окно (до 128,000 токенов) становится решающим преимуществом.[9] Эта особенность архитектуры позволяет обрабатывать целые главы исходного текста в рамках одного прохода нейронной сети. Это критически важно для стилистики Достоевского, так как позволяет модели сохранять долгосрочную нарративную дугу, психологический профиль персонажей и накал философского напряжения на протяжении всего фрагмента, что было бы невозможно при сегментации текста на малые блоки, характерной для моделей предыдущих поколений.

Заключение

Задача переноса современного текста в сложнейшую стилистическую и философскую парадигму Федора Достоевского является серьезным испытанием для систем генеративного искусственного интеллекта. Выбор моделей семейства Qwen (в частности, Qwen 3 8B и Qwen 2.5 7B) предоставляет оптимальную отправную точку благодаря их изначальной глубокой тренировке на гигантских массивах мультиязычных данных и устойчивости к сложным логическим инструкциям.
Реализация подобного проекта в условиях ограниченных вычислительных ресурсов платформы Kaggle (GPU Tesla T4 16GB) требует строгой технической дисциплины. Применение 4-битного квантования и оптимизированных ядер библиотеки Unsloth преодолевает барьеры памяти, делая возможным загрузку и обучение 8-миллиардной модели. В свою очередь, переход от классического метода LoRA к весовой декомпозиции DoRA с обязательным охватом MLP-слоев и рангом не менее 32 решает фундаментальную проблему катастрофического забывания, позволяя нейросети усвоить многосоюзие, полифонию и лексическую плотность Достоевского без уничтожения фактологического ядра исходного текста.
Внедрение трехступенчатого процесса оценки, комбинирующего строгий стилометрический профиль (StyloMetrix), семантическое выравнивание с учетом стемминга (METEOR) и контекстуальный анализ с помощью сильных моделей-судей (LLM-as-a-Judge), формирует надежный аналитический фреймворк. Этот комплексный подход гарантирует, что итоговая модель не просто производит механическую замену современных слов на архаизмы, а генерирует глубокий, психологически достоверный текст, сохраняющий семантическую точность первоисточника, открывая новые перспективы в области вычислительной стилистики и адаптации литературных текстов.

Источники

1. Evaluating Text Style Transfer Evaluation: Are There Any Reliable Metrics? - arXiv, дата последнего обращения: марта 1, 2026, https://arxiv.org/pdf/2502.04718
2. Disentangled Learning with Synthetic Parallel Data for Text Style Transfer - ACL Anthology, дата последнего обращения: марта 1, 2026, https://aclanthology.org/2024.acl-long.811.pdf
3. Evaluating Text Style Transfer Evaluation: Are There Any Reliable Metrics? - ACL Anthology, дата последнего обращения: марта 1, 2026, https://aclanthology.org/2025.naacl-srw.41.pdf
4. Introduction: Dostoevsky and the Novel in Modernity - University of Toronto Press, дата последнего обращения: марта 1, 2026, https://utppublishing.com/doi/10.3138/9781487508630.001
5. “ARTISTIC LANGUAGE AND STYLE IN THE WORKS OF RUSSIAN WRITERS (A CASE STUDY OF L. TOLSTOY AND F. DOSTOEVSKY)” | Mental Enlightenment Scientific-Methodological Journal, дата последнего обращения: марта 1, 2026, https://mentaljournal-jspu.uz/index.php/mesmj/article/view/1103
6. Text Style Transfer with Parameter-efficient LLM Finetuning and Round-trip Translation, дата последнего обращения: марта 1, 2026, https://www.researchgate.net/publication/400855206_Text_Style_Transfer_with_P

arameter-efficient_LLM_Finetuning_and_Round-trip_Translation
7. Finetuning Qwen 3 на RTX4090: полный гайд обучения LLM с ..., дата последнего обращения: марта 1, 2026, https://habr.com/ru/companies/raft/articles/932504/
8. Unsupervised Text Style Transfer for Controllable Intensity - arXiv, дата последнего обращения: марта 1, 2026, https://arxiv.org/html/2601.01060v1
9. Qwen3: Think Deeper, Act Faster | Qwen, дата последнего обращения: марта 1, 2026, https://qwenlm.github.io/blog/qwen3/
10. Qwen - Alibaba Cloud, дата последнего обращения: марта 1, 2026, https://www.alibabacloud.com/en/solutions/generative-ai/qwen?_p_lc=1
11. Qwen/Qwen2.5-72B-Instruct - Hugging Face, дата последнего обращения: марта 1, 2026, https://huggingface.co/Qwen/Qwen2.5-72B-Instruct
12. Kaggle Qwen 2.5 Unsloth notebook, дата последнего обращения: марта 1, 2026, https://www.kaggle.com/code/danielhanchen/kaggle-qwen-2-5-unsloth-notebook
13. Qwen2_5_7B_VL_GRPO.ipynb - Colab - Google, дата последнего обращения: марта 1, 2026, https://colab.research.google.com/github/unslothai/notebooks/blob/main/nb/Qwen2_5_7B_VL_GRPO.ipynb
14. Fine-tuning a LLM using Unsloth - Kaggle, дата последнего обращения: марта 1, 2026, https://www.kaggle.com/code/sharafatahmed/fine-tuning-a-llm-using-unsloth
15. Fine-tuning Small Language models/ qwen2.5 0.5 B : r/LocalLLaMA - Reddit, дата последнего обращения: марта 1, 2026, https://www.reddit.com/r/LocalLLaMA/comments/1nipox6/finetuning_small_language_models_qwen25_05_b/
16. unsloth/Qwen2.5-7B-Instruct - Hugging Face, дата последнего обращения: марта 1, 2026, https://huggingface.co/unsloth/Qwen2.5-7B-Instruct
17. Qwen3-8B - Model Info, Parameters, Benchmarks - SiliconFlow, дата последнего обращения: марта 1, 2026, https://www.siliconflow.com/models/qwen3-8b
18. Qwen3 - How to Run & Fine-tune | Unsloth Documentation, дата последнего обращения: марта 1, 2026, https://unsloth.ai/docs/models/qwen3-how-to-run-and-fine-tune
19. Fine Tune Qwen 2.5 With TRL & Unsloth - YouTube, дата последнего обращения: марта 1, 2026, https://www.youtube.com/watch?v=iPoxDPhAeK0
20. Qwen2.5: A Party of Foundation Models! | Qwen, дата последнего обращения: марта 1, 2026, https://qwenlm.github.io/blog/qwen2.5/
21. Qwen3 is the large language model series developed by Qwen team, Alibaba Cloud. - GitHub, дата последнего обращения: марта 1, 2026, https://github.com/QwenLM/Qwen3
22. unslothai/unsloth: Fine-tuning & Reinforcement Learning for LLMs. Train OpenAI gpt-oss, DeepSeek, Qwen, Llama, Gemma, TTS 2x faster with 70% less VRAM. - GitHub, дата последнего обращения: марта 1, 2026, https://github.com/unslothai/unsloth
23. unsloth/README.md at main · unslothai/unsloth · GitHub, дата последнего

обращения: марта 1, 2026, https://github.com/unslothai/unsloth/blob/main/README.md
24. Qwen 2.5 Coder Fine-tuning - Unsloth AI, дата последнего обращения: марта 1, 2026, https://unsloth.ai/blog/qwen-coder
25. unsloth - PyPI, дата последнего обращения: марта 1, 2026, https://pypi.org/project/unsloth/
26. Kaggle Qwen 2.5 Coder 7B Base, дата последнего обращения: марта 1, 2026, https://www.kaggle.com/code/danielhanchen/kaggle-qwen-2-5-coder-7b-base
27. Kaggle Qwen 2.5 Conversational Unsloth, дата последнего обращения: марта 1, 2026, https://www.kaggle.com/code/danielhanchen/kaggle-qwen-2-5-conversational-unsloth
28. [Bug]When using the latest version of Unsloth on Kaggle to run Python and load the model, an error occurs: "NameError: name 'PeftModelForCausalLM_fast_forward' is not defined". (The Unsloth version from June 16, 2025, does not have this issue.) · Issue #2759 · unslothai/unsloth - GitHub, дата последнего обращения: марта 1, 2026, https://github.com/unslothai/unsloth/issues/2759
29. Qwen3-8B-Unsloth-4bit-Quantized - Kaggle, дата последнего обращения: марта 1, 2026, https://www.kaggle.com/datasets/mavicbf/qwen3-8b-unsloth-4bit-quantized
30. Troubleshooting & FAQs | Unsloth Documentation, дата последнего обращения: марта 1, 2026, https://unsloth.ai/docs/basics/troubleshooting-and-faqs
31. Building SamKash-Tolstoy: a LoRA based LLM that lives and breathes Russian literature, дата последнего обращения: марта 1, 2026, https://medium.com/@kashsala/building-samkash-tolstoy-a-tiny-lora-llm-that-lives-and-breathes-russian-literature-ca959747af4a
32. Fyodor Dostoevsky - Tony McKibbin, дата последнего обращения: марта 1, 2026, https://tonymckibbin.com/article/fyodor-dostoevsky.html
33. About Dostoyevsky's writing style - literature - Reddit, дата последнего обращения: марта 1, 2026, https://www.reddit.com/r/literature/comments/1he7gua/about_dostoyevskys_writing_style/
34. StyloMetrix/resources/metrics_list_ru.md at main · ZILiAT-NASK ..., дата последнего обращения: марта 1, 2026, https://github.com/ZILiAT-NASK/StyloMetrix/blob/main/resources/metrics_list_ru.md
35. Interviews as Stylistic and Rhetorical Techniques in Dostoyevsky's Crime and Punishment - Pakistan Review, дата последнего обращения: марта 1, 2026, https://www.pakistanreview.com/index.php/PRSS/article/download/197/140/691
36. Distilling Text Style Transfer With Self-Explanation From LLMs - arXiv, дата последнего обращения: марта 1, 2026, https://arxiv.org/html/2403.01106v1
37. Text simplification as a controlled text style transfer task - international conference, дата последнего обращения: марта 1, 2026, https://dialogue-conf.org/media/5931/tikhonovamplusfenogenovaa016.pdf

38. Fine-Tuning Qwen for Image-Text-to-Text Task on a Single T4 GPU Using Unsloth and TRL, дата последнего обращения: марта 1, 2026, https://pub.towardsai.net/fine-tuning-qwen-for-image-to-text-extraction-on-a-single-t4-gpu-using-unsloth-and-trl-15918f6899c9
39. Dataset formats and types - Hugging Face, дата последнего обращения: марта 1, 2026, https://huggingface.co/docs/trl/en/dataset_formats
40. 50+ Tested System Prompts That Work Across AI Models in 2025 - AI Chat, дата последнего обращения: марта 1, 2026, https://chatlyai.app/blog/best-system-prompts-for-everyone
41. Findings from LoRA Finetuning for Qwen3 : r/LocalLLaMA - Reddit, дата последнего обращения: марта 1, 2026, https://www.reddit.com/r/LocalLLaMA/comments/1kkl39r/findings_from_lora_finetuning_for_qwen3/
42. Issues with Fine-Tuning a 7B Qwen2.5 Model for Text Categorization in Unsloth - Reddit, дата последнего обращения: марта 1, 2026, https://www.reddit.com/r/unsloth/comments/1jdlecp/issues_with_finetuning_a_7b_qwen25_model_for_text/
43. Fine-Tuning LLM with Unsloth: A Practical Guide to Training Models like Qwen3 8B on Consumer GPU | by İsmail Kağan Acar | Medium, дата последнего обращения: марта 1, 2026, https://medium.com/@acarismailkagan/fine-tuning-llm-with-unsloth-a-practical-guide-to-training-models-like-qwen3-8b-on-a-consumer-gpu-4116088a207c
44. LoRA Without Regret - Thinking Machines Lab, дата последнего обращения: марта 1, 2026, https://thinkingmachines.ai/blog/lora/
45. Understanding alpha parameter tuning in LORA paper - Data Science Stack Exchange, дата последнего обращения: марта 1, 2026, https://datascience.stackexchange.com/questions/123229/understanding-alpha-parameter-tuning-in-lora-paper
46. Fine-Tuning Qwen2.5-3B-Instruct (GRPO, PEFT) - Kaggle, дата последнего обращения: марта 1, 2026, https://www.kaggle.com/code/ksmooi/fine-tuning-qwen2-5-3b-instruct-grpo-peft
47. Replicate an Author's Writing Style Using Prompt Engineering - DEV Community, дата последнего обращения: марта 1, 2026, https://dev.to/thatechmaestro/replicate-an-authors-writing-style-using-prompt-engineering-insights-from-an-experiment-with-2hfk
48. lightblue/DeepSeek-R1-Distill-Qwen-7B-Multilingual - Hugging Face, дата последнего обращения: марта 1, 2026, https://huggingface.co/lightblue/DeepSeek-R1-Distill-Qwen-7B-Multilingual
49. Evaluating Text Style Transfer Evaluation: Are There Any Reliable Metrics? - arXiv, дата последнего обращения: марта 1, 2026, https://arxiv.org/abs/2502.04718
50. Automated Metrics for Evaluating Text Style Transfer - Fast Forward Labs, дата последнего обращения: марта 1, 2026, https://blog.fastforwardlabs.com/2022/07/11/automated-metrics-for-evaluating-text-style-transfer.html

51. Evaluating Style Transfer for Text - ACL Anthology, дата последнего обращения: марта 1, 2026, https://aclanthology.org/N19-1049/
52. ZILiAT-NASK/StyloMetrix: StyloMetrix - GitHub, дата последнего обращения: марта 1, 2026, https://github.com/ZILiAT-NASK/StyloMetrix
53. Stylometry recognizes human and LLM-generated texts in short samples - arXiv.org, дата последнего обращения: марта 1, 2026, https://arxiv.org/html/2507.00838v1
54. Stylometry-based Approach for Detecting Writing Style Changes in Literary Texts, дата последнего обращения: марта 1, 2026, https://www.scielo.org.mx/scielo.php?script=sci_arttext&pid=S1405-55462018000100047
55. metrics_list_en.md - ZILiAT-NASK/StyloMetrix - GitHub, дата последнего обращения: марта 1, 2026, https://github.com/ZILiAT-NASK/StyloMetrix/blob/v0.1.0/resources/metrics_list_en.md
56. Stylometry recognizes human and LLM-generated texts in short samples - arXiv, дата последнего обращения: марта 1, 2026, https://arxiv.org/html/2507.00838v2
57. LLM Evaluation - Clarifai Docs, дата последнего обращения: марта 1, 2026, https://docs.clarifai.com/create/models/evaluate/llms/
58. LLM-Judge Evaluation Techniques - Emergent Mind, дата последнего обращения: марта 1, 2026, https://www.emergentmind.com/topics/llm-judge-evaluation
59. LLM-as-a-Judge: Rethinking Model-Based Evaluations in Text Generation - Han Lee, дата последнего обращения: марта 1, 2026, https://leehanchung.github.io/blogs/2024/08/11/llm-as-a-judge/
60. llm-as-a-judge/Awesome-LLM-as-a-judge - GitHub, дата последнего обращения: марта 1, 2026, https://github.com/llm-as-a-judge/Awesome-LLM-as-a-judge
61. Qwen 3 Performance: Quick Benchmarks Across Different Setups : r/LocalLLaMA - Reddit, дата последнего обращения: марта 1, 2026, https://www.reddit.com/r/LocalLLaMA/comments/1kdsp4z/qwen_3_performance_quick_benchmarks_across/